

Universidad Central de Venezuela

Facultad de Ciencias Económicas y Sociales

Escuela de Estadística y Ciencias Actuariales

**Motor Predictivo Estocástico basado en el Modelo
de Poisson Bivariado para la Detección de Valor
Esperado en Mercados Deportivos.**

Autor: Ronald Maneiro

Abril 2026

Introducción

La predicción de resultados deportivos ha transitado desde la especulación heurística hacia el modelaje estocástico y el análisis cuantitativo riguroso. En el caso específico del fútbol, su naturaleza de baja puntuación permite que la ocurrencia de goles se modele inicialmente mediante distribuciones de probabilidad para eventos discretos en intervalos fijos. El presente trabajo detalla el diseño, desarrollo e implementación del "Premier League Predictor", un motor de inferencia estadística automatizado que supera la aplicación clásica de la distribución de Poisson al incorporar ajustes paramétricos avanzados (modelo bivariado con corrección de Dixon-Coles) para proyectar con alta precisión marcadores exactos y probabilidades de victoria (1X2).

A través de una arquitectura de software escalable que integra el procesamiento en bases de datos relacionales con un panel de visualización analítica en tiempo real, este proyecto trasciende la mera predicción deportiva. Su objetivo fundamental es la gestión del riesgo financiero: identificar ineficiencias sistemáticas en las cuotas de los mercados, validar empíricamente la existencia de Valor Esperado (EV) positivo mediante *backtesting*, y aplicar teoremas de optimización, como el Criterio de Kelly, para la correcta asignación de capital a largo plazo.

CAPITULO I

Planteamiento del Problema

En la actualidad, los mercados de activos deportivos operan bajo una estructura de alta eficiencia financiera, donde las cuotas ofrecidas por los bookmakers actúan como estimadores de probabilidad implícita. Estas cuotas, sin embargo, no representan la probabilidad pura del evento, sino una versión sesgada y ajustada por el margen de beneficio de la casa o overround, lo que garantiza, bajo condiciones normales, una esperanza matemática negativa para el participante promedio.

A pesar de esta aparente eficiencia, el mercado deportivo presenta ineficiencias sistemáticas derivadas de sesgos cognitivos del público —como el sesgo de representatividad o el exceso de confianza— y de la incapacidad de procesar de manera integral la varianza a corto plazo. El problema fundamental radica en la complejidad técnica de procesar volúmenes masivos de datos históricos para aislar las variables paramétricas de fuerza ofensiva y defensiva de un equipo en tiempo real. Sin un modelo estocástico que actúe como contrapunto científico, el analista queda desprovisto de una herramienta para identificar discrepancias entre la probabilidad teórica y la cuota de mercado.

Asimismo, el desafío predictivo trasciende la mera estimación de resultados. En un entorno profesional, la incertidumbre residual y la volatilidad intrínseca del fútbol exigen mecanismos de Asignación Óptima de Capital. La carencia de una métrica que vincule la ventaja estadística (Edge) con la exposición financiera somete al analista al riesgo de ruina o quiebra del capital (Gambler's Ruin), invalidando cualquier modelo predictivo, por muy preciso que sea, si este no se integra en un marco de gestión de carteras robusto.

Objetivo General

Diseñar e implementar una plataforma analítica integral sustentada en un motor de inferencia estadística basado en el modelo de Poisson Bivariado con ajustes de Dixon-Coles, capaz de cuantificar ventajas probabilísticas y automatizar la gestión de riesgos financieros en mercados deportivos mediante el cálculo de Valor Esperado (EV) y la aplicación del Criterio de Kelly.

Objetivos Específicos

- **Ingeniería de Datos:** Estructurar y normalizar un conjunto de datos crudos (Raw Data) de más de 3,000 encuentros de ligas europeas en un sistema de gestión de bases de datos relacionales (**PostgreSQL**) para optimizar consultas de alta velocidad.
- **Inferencia Paramétrica:** Calcular dinámicamente las fuerzas de ataque y defensa de los equipos mediante la desviación respecto al promedio de goles de la liga, incorporando ponderaciones temporales para capturar la inercia reciente.
- **Modelado Estocástico:** Implementar el ajuste de Dixon-Coles en matrices de Poisson bivariadas para corregir la subestimación de empates y proyectar con precisión marcadores exactos y probabilidades 1X2.
- **Gestión de Riesgo:** Integrar un módulo de cálculo de Esperanza Matemática y Criterio de Kelly para dictaminar la fracción óptima de inversión y mitigar el riesgo de ruina actuarial.
- **Validación Empírica:** Someter el motor a pruebas de backtesting histórico para verificar el Winrate estratégico y el Retorno de Inversión (ROI) bajo condiciones de mercado simuladas.

Justificación

Desde la perspectiva de las Ciencias Actariales, este proyecto constituye una aplicación práctica de la teoría de procesos estocásticos y la estadística no paramétrica a la optimización de carteras de inversión de alto riesgo. Al sustituir el análisis subjetivo por un modelo de distribución de variables aleatorias discretas, se establece un marco científico para la toma de decisiones bajo incertidumbre, eliminando los sesgos emocionales del proceso.

Tecnológicamente, el proyecto justifica la integración de flujos de datos (pipelines) complejos: desde el almacenamiento estructurado en SQL hasta la visualización asíncrona en interfaces web modernas. Representa una solución robusta que demuestra cómo la arquitectura de software contemporánea puede democratizar el acceso a herramientas de análisis cuantitativo que anteriormente estaban reservadas para fondos de cobertura (Hedge Funds) o analistas profesionales de mercados de capitales.

CAPÍTULO II

MARCO TEÓRICO

2.1. El Fútbol como Proceso Estocástico de Poisson

La naturaleza del fútbol lo distingue de otros deportes por su baja frecuencia de eventos de puntuación. Estadísticamente, la ocurrencia de un gol puede modelarse como un proceso de Poisson puntual en un intervalo continuo de tiempo ($t = 90$ min). Bajo este esquema, se asumen tres condiciones fundamentales:

1. **Probabilidad Proporcional:** La probabilidad de que ocurra un gol en un intervalo de tiempo muy pequeño es proporcional a la duración de dicho intervalo.
2. **No Simultaneidad:** La probabilidad de que ocurran dos o más goles en un instante infinitamente pequeño es despreciable.
3. **Independencia Incremental:** El número de goles marcados en intervalos de tiempo disjuntos son variables aleatorias independientes.

2.2. La Distribución de Poisson

La distribución de Poisson es la herramienta paramétrica idónea para modelar variables aleatorias discretas que representan el conteo de eventos independientes a una tasa constante (λ). Su Función de Masa de Probabilidad (PMF) se define como:

$$P(x = k) = \frac{\lambda^k \cdot e^{-\lambda}}{k!}$$

Donde la propiedad más relevante para el análisis actuarial es que la esperanza matemática y la varianza de la distribución son equivalentes al parámetro λ ($E[X] = \text{Var}(X) = \lambda$). En el contexto de este motor, λ representa el valor de Goles Esperados (xG), derivado de la fuerza relativa de ataque de un equipo frente a la capacidad defensiva del rival.

2.3. Modelado Bivariado y el Ajuste de Dixon-Coles

Para proyectar un marcador exacto, se utiliza inicialmente el modelo de Independencia Bivariada, donde el resultado (i, j) es el producto de las probabilidades marginales del local (X) y el visitante (Y):

$$P(X = i, Y = j) = \frac{\lambda_x^i * e^{-\lambda}}{i!} \times \frac{\lambda_y^j * e^{-\lambda}}{j!}$$

Sin embargo, este modelo presenta un sesgo conocido: la subestimación de empates de baja puntuación (0-0, 1-1). Para corregir esta deficiencia de independencia, se implementó el Ajuste de Dixon-Coles (1997). Este refinamiento introduce un parámetro de dependencia ρ (Rho) que modifica la matriz de probabilidad mediante una función de corrección τ :

- Si $(x,y) \in \{(0,0), (1,1), (0,1), (1,0)\}$, se aplica el ajuste τ para redistribuir la masa de probabilidad y reflejar la correlación real del juego.
- Para cualquier otro marcador, $\tau = 1$.

Esta corrección transforma la distribución simple en un modelo bivariado con dependencia negativa, capturando la fricción táctica que ocurre en los primeros niveles de anotación.

2.4. Derivación de Mercados Secundarios

A partir de la matriz de probabilidad bivariada de $n \times n$ (donde $n=5$ goles), es posible extraer mediante agregación de celdas las probabilidades de mercados complejos:

- **Over/Under 2.5 Goles:** Se obtiene mediante la sumatoria de todas las celdas (i, j) donde la suma de los índices es mayor o menor a 2.5.

$$P(\text{Over 2.5}) = \sum_{\{i+j > 2.5\}} P(X=i, Y=j)$$

$$P(\text{Over 2.5}) = \sum_{\{i + j > 2.5\}} P(X = i, Y = j)$$

- **Ambos Equipos Anotan (BTTS):** Se calcula como el complemento de la probabilidad de que al menos un equipo no marque.

$$P(\text{BTTS}) = 1 - [P(X = 0) + P(Y = 0) - P(X = 0, Y = 0)]$$

2.5. Gestión de Riesgo y Optimización Actuarial

El objetivo final del motor no es solo la predicción, sino la explotación de ineficiencias mediante el Valor Esperado (EV). El EV es el operador lineal que determina la ganancia o pérdida promedio a largo plazo:

$$EV = (P_{\text{modelo}} \times Cuota_{\text{mercado}}) - 1$$

Si $EV > 0$, existe una ventaja estadística o Edge. Para gestionar esta ventaja sin incurrir en el riesgo de ruina, se aplica el Criterio de Kelly. Este teorema de optimización de carteras dicta la fracción del capital (f^*) a exponer basándose en la magnitud de la ventaja y la probabilidad de éxito:

$$f^* = \frac{p(b - 1) - q}{b - 1}$$

Donde p es la probabilidad del modelo, b es la cuota decimal y $q = 1 - p$. En la práctica actuarial, este valor suele ajustarse a un "Kelly Fraccional" (ej. 1/4 Kelly) para mitigar la volatilidad y preservar la solvencia de la cartera.

2.6. Visualización de la Función de Masa de Probabilidad (PMF)

La visualización mediante curvas de densidad de áreas superpuestas permite analizar la Moda de la distribución y su Asimetría (Skewness). La moda representa el escenario de máxima verosimilitud, mientras que la dispersión de las áreas bajo la curva indica el nivel de incertidumbre o varianza esperada en el encuentro, permitiendo al analista diferenciar entre un partido de "pronóstico cerrado" y uno de "alta volatilidad".

CAPÍTULO III

MARCO METODOLÓGICO

3.1. Diseño y Tipo de Investigación

La presente investigación se enmarca en un paradigma cuantitativo de tipo aplicada, con un nivel de profundidad descriptivo-proyectivo. Desde una perspectiva metodológica, el sistema utiliza series de datos longitudinales retrospectivos (historial de partidos) para parametrizar el modelo y, consecuentemente, generar proyecciones estocásticas transversales aplicables al contexto actual. Adicionalmente, el diseño incorpora una fase cuasiexperimental evaluativa mediante técnicas de backtesting, sometiendo el algoritmo paramétrico a miles de iteraciones sobre resultados históricos para cuantificar su Esperanza Matemática y validar su eficacia empírica.

3.2. Tratamiento de Datos y Arquitectura (Data Pipeline)

La población de estudio está conformada por un repositorio histórico extenso de partidos de las principales ligas europeas, originalmente estructurado en formato de archivo local (SQLite). Mediante la implementación de un proceso de Extracción, Transformación y Carga (ETL) soportado por librerías especializadas en análisis de datos (Pandas), la información cruda (Raw Data) fue depurada, normalizada y exportada hacia un motor relacional avanzado.

Para garantizar la eficiencia computacional y evitar cuellos de botella en la memoria del servidor, el cálculo de las métricas de desempeño se delegó a la base de datos a través de Vistas SQL dinámicas (ej. Team_strengths). Esta arquitectura matricial asegura que el motor lógico consuma siempre la inercia estadística más actualizada de cada equipo para la conformación de los Lambdas Dinámicos, sin necesidad de recalcular iteraciones pesadas en el Backend.

3.3. Stack Tecnológico y Componentes del Sistema

El motor fue desarrollado bajo una arquitectura de microservicios modularizada en tres capas funcionales (Three-Tier Architecture):

- **Capa de Persistencia (Motor de Base de Datos):** Soportada por PostgreSQL. Seleccionado por su robustez transaccional, integridad referencial y su alta capacidad para ejecutar consultas de agregación paramétrica sobre grandes volúmenes de datos.
- **Capa Lógica (Backend / API REST):** Desarrollada en Python 3.10+ bajo el framework asíncrono **FastAPI**. Constituye el núcleo algorítmico del sistema. Para la ejecución matemática, emplea la librería **SciPy** en el cálculo vectorizado de la Función de Masa de Probabilidad (PMF) de Poisson, y **NumPy** para la generación matricial eficiente del producto externo (`np.outer`), consolidando la matriz bivariada final y aplicando los ajustes de Dixon-Coles.
- **Capa de Presentación (Frontend / Cliente):** Construida en JavaScript utilizando el framework de renderizado **Next.js** (basado en la biblioteca React), con una interfaz gráfica estilizada a través de Tailwind CSS. Esta capa centraliza la interacción humana con los vectores estocásticos.

3.4. Visualización Dinámica y Optimización Computacional

Para resolver el desafío de transmitir información estadística compleja al usuario final, se implementaron dos estrategias arquitectónicas clave:

- **Renderizado Estocástico Visual:** Se integró la librería Recharts (basada en D3.js) para la representación dinámica de datos estocásticos directamente en el navegador del cliente. Esta herramienta transforma los vectores unidimensionales generados por Poisson en gráficos de áreas de densidad superpuestas, facilitando la identificación visual de la moda estadística y la dispersión (varianza) del evento.
- **Optimización por Distribución de Carga:** Bajo el principio de separación de responsabilidades, el sistema delega el cómputo matricial pesado al servidor Python, mientras que los cálculos correspondientes a la gestión de riesgo financiero —como el Valor Esperado (EV) iterativo y el cálculo fraccional del Criterio de Kelly— se ejecutan exclusivamente en la lógica del Frontend. Esta decisión arquitectónica elimina drásticamente la latencia de red, permitiendo una actualización y respuesta inmediata en la interfaz gráfica ante cualquier simulación o cambio en las cuotas de mercado introducidas por el analista.

CAPÍTULO IV

ANÁLISIS Y RESULTADOS (ESTRUCTURA DEL MODELO Y VALIDACIÓN EMPÍRICA)

4.1. Parametrización Dinámica de Goles Esperados (λ)

El núcleo algorítmico del cálculo estocástico requiere estimar la tasa media de ocurrencia (goles esperados) para cada equipo en un enfrentamiento específico. Para lograr una aproximación paramétrica precisa, se cruza la fuerza ofensiva del equipo local con la vulnerabilidad defensiva del equipo visitante, ajustando el producto final por el promedio histórico de la liga respectiva.

Las fórmulas implementadas en la API matemática se definen como:

$$\lambda_{local} = FuerzaAtq_{local} \times FuerzaDef_{visitante} \times PromedioGoles_{local}$$

$$\lambda_{visitante} = FuerzaAtq_{visitante} \times FuerzaDef_{local} \times PromedioGoles_{visitante}$$

4.2. Generación Bivariada y Ajuste Estocástico de la Matriz

Con los valores paramétricos λ definidos para ambos equipos, el servidor en FastAPI ejecuta el cálculo computacional utilizando el método `poisson.pmf` de la librería científica SciPy. Este proceso itera el cálculo de probabilidades desde 0 hasta 5 goles, estableciendo este último valor como el límite superior de tolerancia dado que las probabilidades marginales de anotar más de 5 goles tienden asintóticamente a cero.

Posteriormente, mediante el producto externo de NumPy (`np.outer`), se genera una matriz de probabilidad bivariada inicial de 6×6 , la cual contiene el espacio muestral de todos los marcadores exactos posibles (desde el 0-0 hasta el 5-5). En esta fase del pipeline, el algoritmo aplica iterativamente la función de corrección de Dixon-Coles sobre los marcadores de baja puntuación para redistribuir la masa de probabilidad, mitigando el error de independencia y ajustando el modelo a la realidad táctica del deporte.

4.3. Agregación de Cuadrantes (El Mercado 1X2)

Para traducir la matriz de 36 marcadores exactos en probabilidades útiles para los mercados de victoria, empate o derrota (1X2), el algoritmo secciona y suma matemáticamente los sectores de la matriz generada:

- **Probabilidad de Empate (P_{empate}):** Sumatoria de la diagonal principal de la matriz mediante la función `np.diag`, la cual aísla exclusivamente los escenarios donde $X = Y$ (0-0, 1-1, 2-2, etc.).
- **Probabilidad Local (P_{local}):** Sumatoria del triángulo inferior de la matriz utilizando `np.tril`, capturando así todos los eventos probabilísticos donde $X > Y$.
- **Probabilidad Visitante ($P_{\text{visitante}}$):** Sumatoria del triángulo superior de la matriz extrayendo los datos con `np.triu`, representando estrictamente los casos donde $Y > X$.

4.4. Automatización del Veredicto Estadístico y Análisis Visual

La inferencia paramétrica culmina en el cliente web (Next.js), el cual integra un algoritmo de interpretación de datos diseñado para traducir métricas abstractas en directrices verbales y visuales de alta comprensión:

- **Evaluación Táctica:** El sistema evalúa las probabilidades finales e imprime un análisis automatizado. A modo de ejemplo, si el marcador de máxima verosimilitud extraído de la matriz presenta una sumatoria mayor a 2 goles, el sistema recomienda rechazar las líneas tradicionales de victoria (1X2) y sugiere desviar el capital hacia el mercado de totales (Over 2.5), mitigando drásticamente la exposición al riesgo asociado a la varianza del partido.
- **Análisis de Densidad Superpuesta:** El motor renderiza un gráfico de áreas donde las densidades estocásticas de ambos equipos interactúan visualmente. Un alto grado de solapamiento en las curvas indica una paridad absoluta de fuerzas, mientras que la asimetría y el desplazamiento de los picos de probabilidad (modas) hacia la derecha confirman y cuantifican la superioridad ofensiva de una de las escuadras.
- **Detección Automática de Valor (EV+):** El sistema efectúa la comparación automatizada entre la probabilidad teórica calculada y las cuotas introducidas. Si el resultado de la Esperanza Matemática es positivo ($EV > 0$), el motor emite un

veredicto validando empíricamente la existencia de una ineficiencia o anomalía en el mercado analizado, recomendando la inversión bajo parámetros del Criterio de Kelly.

4.5. Validación Empírica del Modelo (Backtesting Actuarial)

Para comprobar la viabilidad financiera del "Premier League Predictor", se diseñó y ejecutó un entorno de simulación algorítmica (Backtesting). Esta prueba retrospectiva evaluó un registro histórico de 3,040 partidos oficiales.

El modelo operó bajo condiciones de filtro estricto de Valor Esperado ($EV > 0$), lo que significa que el algoritmo fue programado para abstenerse de operar en mercados eficientes, ejecutando asignaciones de capital únicamente cuando detectaba una ventaja probabilística superior al margen de las casas de apuestas simuladas.

Resultados de la Simulación:

- **Universo de Partidos Procesados:** 3,040 encuentros.
- **Operaciones Ejecutadas (Filtro $EV > 0$):** 1,063 inversiones.
- **Tasa de Acierto Estratégico (Winrate):** 62.46% (664 predicciones correctas).
- **Capital Inicial Estructurado:** \$1,000.00.
- **Capital Final Obtenido:** \$4,218.42.
- **Retorno de Inversión (ROI) Acumulado:** 321.84%.

La convergencia de estos resultados empíricos demuestra estadísticamente que la integración del parámetro dinámico de fuerza, la corrección de Dixon-Coles y la gestión selectiva de capital superan la barrera teórica de la Esperanza Matemática negativa, transformando el motor predictivo en un instrumento financieramente rentable a largo plazo.

CAPÍTULO V

CONCLUSIONES Y RECOMENDACIONES

5.1. Conclusiones

La culminación de este proyecto de investigación y desarrollo tecnológico permite establecer las siguientes conclusiones desde la perspectiva de la estadística computacional y el análisis de riesgo:

1. **Viabilidad del Modelado Estocástico con Ajustes Paramétricos:** Quedó demostrado que el fútbol puede ser modelado eficazmente como un proceso estocástico. Sin embargo, la aplicación pura de la distribución de Poisson es insuficiente debido al supuesto de independencia. La implementación del modelo bivariado con la corrección de dependencia negativa de Dixon-Coles probó ser fundamental para ajustar la matriz de probabilidades, capturando de forma realista la fricción táctica que genera la alta frecuencia de empates de baja puntuación en el deporte de élite.
2. **El Valor Esperado como Eje de la Rentabilidad:** La predicción aislada carece de utilidad financiera si no se contrasta con la eficiencia del mercado. La integración del cálculo automatizado de Valor Esperado (EV) y la asignación fraccional de capital mediante el Criterio de Kelly transformaron un simple motor de pronósticos en un instrumento de gestión actuarial de carteras. El sistema demostró que la disciplina de rechazar mercados sin ventaja matemática ($EV < 0$) es la única vía para evitar la ruina a largo plazo.
3. **Validación Empírica Excepcional:** La ejecución del backtesting sobre una muestra histórica de 3,040 partidos corroboró la solidez de la arquitectura. Al utilizar parámetros dinámicos y filtrar estrictamente las operaciones mediante la detección de Esperanza Matemática Positiva, el algoritmo ejecutó 1,063 inversiones con un Winrate estratégico del 62.46%, generando un Retorno de Inversión (ROI) acumulado del 321.84%. Esto evidencia categóricamente que el modelo es capaz de superar el overround o margen de ganancia de las casas de apuestas.

4. **Eficiencia de la Arquitectura Full-Stack:** La descentralización del cómputo en un flujo de tres capas demostró ser óptima. La delegación del cálculo matricial pesado al Backend (FastAPI con Python y SciPy) y la ejecución de la gestión de riesgo iterativa en el Frontend (Next.js con Recharts) garantizan una experiencia asíncrona, robusta y libre de latencia, democratizando el acceso a herramientas cuantitativas de nivel institucional.

5.2. Recomendaciones y Líneas de Investigación Futuras

El "Premier League Predictor" sienta las bases para un sistema escalable. Para futuras expansiones del proyecto, se plantean las siguientes líneas de desarrollo tecnológico y estadístico:

1. **Transición hacia Modelos Micro-Estadísticos (Machine Learning):** Se recomienda evolucionar el enfoque macro-paramétrico (fuerza global de ataque y defensa) hacia una arquitectura de Big Data. Esto implica la construcción de modelos de aprendizaje supervisado, como Random Forests o Redes Neuronales, capaces de procesar un espectro temporal más amplio (ej. 2015 a la actualidad) y de ingerir variables micro-estadísticas, tales como métricas individuales de jugadores, salud, fatiga acumulada, alineaciones confirmadas y condiciones climatológicas.
2. **Ingesta Automatizada de Datos en Tiempo Real:** Para optimizar la operatividad en un entorno de producción continuo, se sugiere reemplazar el repositorio histórico estático por un pipeline dinámico conectado a APIs deportivas. Esto permitirá la actualización automatizada de la base de datos relacional tras la culminación de cada jornada, recalculando la inercia de los equipos sin intervención manual.
3. **Expansión de Mercados Derivados:** Ampliar el alcance del análisis matricial para calcular ineficiencias en mercados de alta volatilidad y mayor rentabilidad potencial, tales como hándicaps asiáticos estadísticos, tiempos exactos de anotación y probabilidad de eventos extremos (colas pesadas de la distribución).

REFERENCIAS BIBLIOGRÁFICAS

Dixon, M. J., & Coles, S. G. (1997). Modelling Association Football Scores and Efficiencies in the Football Betting Market. *Applied Statistics*, 46(2), 265-280.

Maher, M. J. (1982). Modelling Association Football Scores. *Statistica Neerlandica*, 36(3), 109-118.

Kelly, J. L. (1956). A New Interpretation of Information Rate. *Bell System Technical Journal*, 35(4), 917-926.

SciPy.org (2026). SciPy: Open Source Scientific Tools for Python - scipy.stats.poisson.

PostgreSQL Global Development Group (2026). PostgreSQL: The World's Most Advanced Open Source Relational Database.